

Visual Product Search trong E-commerce: Multimodal Retrieval với SCALE, Faiss HNSW và Tái xếp hạng thuộc tính

Trần Hải Đức
MSSV: 23127173

Trường Đại học Khoa học Tự nhiên, VNU-HCM
thduc23@clc.fitus.edu.vn

Trần Hoàng Nam
MSSV: 23127232

Trường Đại học Khoa học Tự nhiên, VNU-HCM
thnam23@clc.fitus.edu.vn

Abstract—Tìm kiếm sản phẩm thương mại điện tử trong thực tế không chỉ dựa trên ảnh mà còn khai thác tên và mô tả sản phẩm, bảng thuộc tính, video và audio. Báo cáo này nghiên cứu bài toán truy hồi sản phẩm đa phương thức trên M5Product, trong đó mỗi listing có thể thiếu một hoặc nhiều modality. Mục tiêu là trả về các sản phẩm vừa tương đồng về biểu hiện thị giác, vừa phù hợp với ngữ nghĩa thương mại và thuộc tính quyết định mua, chẳng hạn siêu danh mục, danh mục, thương hiệu và thông số kỹ thuật.

Phương pháp sử dụng SCALE (Self-harmonized Contrastive Learning) để học unified embedding từ năm modality gồm image, text, table, video và audio. Các encoder riêng, Joint Co-Transformer, masked multimodal learning và SIMCL được dùng để mô hình hóa tương tác giữa các modality, đồng thời giảm ảnh hưởng của dữ liệu thiếu hoặc nhiễu. Trên không gian embedding đã chuẩn hóa, Faiss HNSW thực hiện truy hồi xấp xỉ nhằm thu hẹp catalog thành tập ứng viên; sau đó tăng tái xếp hạng thuộc tính kết hợp độ tương đồng embedding với mức độ khớp metadata để điều chỉnh thứ hạng cuối cùng.

Kết quả thực nghiệm hiện có cho thấy cấu hình cải tiến nâng mAP@10 từ 6.32% lên 16.75% và Precision@10 từ 3.56% lên 8.68%. Báo cáo tách bạch các kết quả tái lập nội bộ với số liệu tham chiếu của SCALE, đồng thời chỉ ra thông tin cần được lưu đầy đủ trong các lần chạy tiếp theo để bảo đảm tái lập và so sánh công bằng với benchmark chính thức.

Index Terms—visual product search, multimodal retrieval, M5Product, SCALE, SIMCL, Joint Co-Transformer, Faiss HNSW, reranking, e-commerce

I. GIỚI THIỆU

A. Bối cảnh và Lý do chọn đề tài

E-commerce đang chuyển từ tìm kiếm dựa hoàn toàn trên từ khóa sang trải nghiệm giàu ngữ cảnh hơn. Tìm kiếm truyền thống yêu cầu người dùng mô tả sản phẩm bằng text như tên mặt hàng, màu sắc, kiểu dáng, vật liệu hoặc thương hiệu. Cách tiếp cận này gặp khó khăn khi người dùng chỉ có ảnh hoặc video tham khảo, không biết tên chính xác của sản phẩm, hoặc khi mô tả của người bán không đồng nhất. Visual search giảm ma sát bằng cách cho phép người dùng cung cấp ảnh hoặc video, từ đó hệ thống học đặc trưng và truy hồi các sản phẩm tương tự [?].

Tuy nhiên, một listing thực tế hiếm khi chỉ gồm ảnh. Sản phẩm thường có caption, bảng thuộc tính, video giới thiệu và

audio tách từ video. Vì vậy, bài toán trong nghiên cứu này được mở rộng từ image-to-image retrieval sang *multimodal product retrieval*: biểu diễn query và sản phẩm từ mọi modality khả dụng rồi tìm các product entry có embedding gần nhất.

B. Phạm vi bài toán

Query được biểu diễn bởi

$$q = (I, T, Tab, V, A), \quad (1)$$

trong đó I , T , Tab , V và A lần lượt là image, text, table, video và audio. Query phải có ít nhất image hoặc video; các modality còn lại có thể thiếu. Catalog được định nghĩa là

$$G = \{p_1, p_2, \dots, p_N\}, \quad (2)$$

với mỗi p_i cũng có thể thiếu một số modality.

Mục tiêu là trả về K product entry có embedding đa phương thức gần query nhất. Khác với image retrieval thuần túy, kết quả không chỉ cần giống về màu sắc hoặc texture mà còn cần phù hợp về ngữ nghĩa thương mại như siêu danh mục, danh mục, thương hiệu và các thuộc tính quyết định mua.

C. Khoảng trống nghiên cứu và Đóng góp

Các hệ thống visual product search hiện có thường tập trung vào image-only hoặc image+text. M5Product/SCALE mở rộng lên năm modality và hỗ trợ missing modality, nhưng retrieval gốc của SCALE sử dụng exact similarity giữa query và gallery, chưa giải quyết trực tiếp bài toán serving trên catalog động và chưa có tăng metadata reranking.

Các đóng góp chính của đề tài gồm:

- 1) Xây dựng pipeline multimodal product retrieval sử dụng SCALE để tạo unified embedding từ image, text, table, video và audio.
- 2) Xây dựng lớp serving bằng Faiss HNSW để lọc nhanh $N > K$ ứng viên trên catalog và hỗ trợ thêm listing mà không cần huấn luyện lại index.
- 3) Đề xuất tăng reranking dựa trên siêu danh mục, danh mục, thương hiệu và thông số nhằm giảm lỗi fine-grained retrieval sau bước lọc embedding.

II. ĐẶC ĐIỂM SẢN PHẨM THƯƠNG MẠI ĐIỆN TỬ VÀ DATASET

A. Khái niệm

Một mẫu sản phẩm thương mại điện tử không chỉ đơn thuần là một ảnh đại diện. Trên trang listing, người mua thường thấy đồng thời hình ảnh, tên/mô tả, bảng thuộc tính, và đôi khi có cả video hay audio đi kèm. Các tín hiệu này cùng mô tả một SKU nhưng không trùng lặp nội dung: ảnh thể hiện hình dáng và màu sắc, bảng thuộc tính chi tiết về thương hiệu/chất liệu/kích thước, còn video/audio thể hiện hướng dẫn sử dụng và góc nhìn thực tế.

Trong bài toán truy hồi, mẫu sản phẩm là đơn vị retrieval cơ bản: hệ thống thực hiện so khớp biểu diễn đa phương thức của query với biểu diễn đa phương thức của từng p_i trong kho catalog, thay vì chỉ so sánh từng ảnh đơn lẻ như các hệ thống image retrieval thuần túy.

B. Ba tính chất then chốt

1) *Dữ liệu có cấu trúc*: Một mẫu sản phẩm thông thường bao gồm năm thành phần modality:

- **Ảnh (Image)**: Thể hiện ngoại quan (appearance), màu sắc, hình dáng sản phẩm.
- **Văn bản (Text)**: Tên sản phẩm, mô tả chi tiết, caption, các điểm bán hàng nổi bật (selling points).
- **Bảng (Table)**: Các cặp key-value lưu trữ thông số kỹ thuật như thương hiệu, chất liệu, kích thước, xuất xứ.
- **Video**: Cung cấp chuyển động đa góc nhìn, độ đàn hồi, trải nghiệm trực quan cách sử dụng.
- **Âm thanh (Audio)**: Lời thuyết minh giới thiệu hoặc âm thanh gốc trích xuất từ video.

Ví dụ: Xét mẫu đồng hồ Casio, ảnh mặt đồng hồ đi kèm caption dòng Accent Color EF-130D-1A2 và bảng thuộc tính (thương hiệu, khả năng chống nước 100m, độ dày 13mm, xuất xứ Nhật Bản, loại hiển thị kim). Không một modality đơn lẻ nào có thể tự cung cấp đầy đủ thông tin để định danh sản phẩm.

2) *Dữ liệu không toàn vẹn*: Không phải listing nào trên sàn e-commerce cũng cung cấp đủ năm modality. Người bán có thể chỉ đăng tải ảnh và title, thiếu hoàn toàn bảng thuộc tính, video hay audio. Bộ dữ liệu M5Product phản ánh chính xác thực tế này: nhiều mẫu sản phẩm bị thiếu một hoặc nhiều modality, trong đó khoảng 5% là mẫu đơn phương thức (unimodal). Hệ thống retrieval không được phép loại bỏ các mẫu thiếu này ra khỏi quá trình huấn luyện hay catalog; việc loại bỏ sẽ làm tổn thất dữ liệu và khiến mô hình kém khả năng nhúng (embedding) các listing thực tế thiếu thông tin.

3) *Dữ liệu cực kỳ đa dạng*: Catalog thương mại điện tử không giới hạn ở một ngành hàng cố định mà trải rộng từ giày dép, đồ gia dụng, nội thất, thực phẩm đến đồng hồ, balo. Hình dáng tổng thể giữa nhiều SKU có thể rất tương đồng (ví dụ: cùng kiểu dáng đế/mũi/dây giày), nhưng điểm khác biệt lại nằm ở model, màu sắc hay chất liệu. Bối cảnh chụp (background) cũng không đồng nhất: từ nền studio trắng tiêu chuẩn đến nền màu phức tạp hoặc môi trường sử dụng thực tế.




Figure 1. Cấu trúc một mẫu trong M5Product với năm modality: image, text/caption, table, video và audio.

Table I
THIẾT KẾ TẬP CON M5PRODUCT DÙNG TRONG NGHIÊN CỨU

Nhóm mẫu	Số lượng	Tỷ lệ
Đủ năm modality	7,000	70%
Thiếu modality	2,000	20%
Đơn phương thức	1,000	10%
Tổng	10,000	100%

C. Bộ dữ liệu M5Product

M5Product là bộ dữ liệu đa phương thức dành cho sản phẩm thương mại điện tử, gồm 6,313,067 mẫu, 6,232 danh mục và hơn 5,000 thuộc tính [?]. Mỗi mẫu có thể chứa category, image, caption, table, video và audio. Hình ?? minh họa năm modality và cách chúng cùng mô tả một sản phẩm: ảnh thể hiện ngoại quan, caption cung cấp mô tả tự do, table lưu thuộc tính cấu trúc, video ghi nhận nhiều khung hình, còn audio bổ sung tín hiệu âm thanh.

D. Xây dựng tập con 10,000 mẫu

Do toàn bộ M5Product có quy mô lớn, nghiên cứu xây dựng một tập con 10,000 mẫu có phân bố ngành hàng và mức độ đầy đủ modality được kiểm soát. Trước hết, taxonomy được dùng để chọn 50 siêu danh mục; từ mỗi siêu danh mục lấy tối đa 200 listing hợp lệ, ưu tiên ảnh có thể đọc được và giảm trùng lặp nguồn. Sau đó, các mẫu được phân tầng theo mức độ đầy đủ modality: 7,000 mẫu có đủ năm modality, 2,000 mẫu thiếu một hoặc nhiều modality và 1,000 mẫu đơn phương thức. Việc giữ lại cả hai nhóm thiếu dữ liệu giúp đánh giá đúng khả năng xử lý missing modality thay vì chỉ đo trên listing hoàn chỉnh.

E. Hệ quả đối với hệ thống Retrieval

Table II
HỆ QUẢ KỸ THUẬT CỦA CÁC ĐẶC ĐIỂM SẢN PHẨM LÊN HỆ THỐNG RETRIEVAL

Tính chất sản phẩm	Hệ quả kỹ thuật trong Retrieval
Có cấu trúc, đa phương thức	Bắt buộc phải có cơ chế dung hợp (fusion), do mỗi nhánh thông tin chỉ chứa một phần ngữ nghĩa của sản phẩm.
Dữ liệu không toàn vẹn	Cần cơ chế mã hóa linh hoạt các mẫu thiếu modality (như Zero Imputation), không được bỏ qua hay xóa dữ liệu.
Đa dạng ngành hàng	Biểu diễn không gian nhúng (embedding) phải mang tính tổng quát, không bị bó hẹp hay thiên lệch vào một ngành hàng cụ thể.

Quy trình truy hồi tổng quát bao gồm: Nhận query đa phương thức → Tiền xử lý từng modality → Trích xuất không gian nhúng → So khớp trên tập catalog → Xếp hạng Top-K.

F. Kết luận chuyển tiếp

Tìm kiếm sản phẩm (Product Search) trong thương mại điện tử không phải là bài toán Image Retrieval thuần túy. Cả bộ dữ liệu lẫn phương pháp xử lý phải sát với dữ liệu thực tế: hỗ trợ đa phương thức, chịu được sự thiếu hụt modality và bao phủ nhiều ngành hàng. Đây chính là lý do nghiên cứu lựa chọn bộ dữ liệu M5Product cùng mô hình SCALE, đồng thời xây dựng tập subset 10.000 mẫu đại diện nhưng vẫn giữ nguyên tỉ lệ phân bố đầy đủ/thiếu hụt của các modality.

III. NGHIÊN CỨU LIÊN QUAN

A. M5Product và SCALE

M5Product được đề xuất để giải quyết giới hạn của pre-training đa phương thức chỉ dựa trên image-text. Dataset gồm 6,313,067 mẫu, 6,232 category, hơn 5.000 thuộc tính và năm modality: image, text, table, video và audio [?]. Khoảng 20% mẫu thiếu một hoặc nhiều modality và khoảng 5% là unimodal, phản ánh dữ liệu listing không hoàn chỉnh trong e-commerce.

SCALE sử dụng kiến trúc single-stream: mỗi modality được mã hóa bởi encoder tương ứng, token của các nhánh được kết hợp và đưa vào Joint Co-Transformer. Bên cạnh masked tasks, SIMCL học trọng số tương tác giữa các modality thay vì giả định mọi cặp modality có mức hỗ trợ như nhau.

B. Visual Product Retrieval

Shopsy tập trung vào image-to-image retrieval trong điều kiện ảnh bị nén, crop, scribble hoặc logo reseller. Phương pháp kết hợp attribute classification, triplet ranking và cơ chế chống nhiễu ảnh, sau đó sử dụng ANN retrieval như HNSW/ScaNN [?].

MIEM là hệ thống multimodal item embedding cho Shopee, kết hợp nhiều ảnh sản phẩm với title bằng merge-attention và

Table III
SO SÁNH CÁC HƯỚNG TIẾP CẬN LIÊN QUAN

Phương pháp	Modality	Thiếu Modality	Chỉ mục
Shopsy	Image	Không	HNSW/ScaNN
MIEM	Image + Text	Hạn chế	HNSW
MRSE	Text + Image + History	Không	HNSW
FashionMV	Multi-view + Text	Theo view	Product embedding
SCALE + HNSW (đề xuất)	I/T/Tab/V/A	Có	HNSW

xây dựng HNSW index [?]. Tuy nhiên, query chủ yếu là ảnh và catalog không bao phủ table, video và audio.

MRSE sử dụng two-tower architecture và mixture-of-experts cho text, image và user history trong hệ thống tìm kiếm quy mô lớn [?]. Hệ thống phù hợp với production search nhưng khác với bài toán năm modality của M5Product.

FashionMV/ProCIR giải quyết composed image retrieval trong miền thời trang bằng multi-view image và modification text [?]. Phương pháp xử lý view incompleteness tốt nhưng phạm vi vẫn hẹp hơn catalog e-commerce đa ngành và năm modality.

C. Điểm đặc biệt của SCALE + Faiss

Điểm đặc biệt của hệ thống là kết hợp hai thành phần có vai trò tách bạch. SCALE là representation backbone: thay vì chủ yếu ghép image với text, mô hình học biểu diễn chung cho image, text, table, video và audio. Joint Co-Transformer cho phép các modality tương tác trực tiếp; SIMCL tự học mức độ hỗ trợ giữa các cặp modality; còn zero imputation kết hợp attention mask giúp xử lý listing thiếu thông tin. Nhờ đó, SCALE học được liệu sản phẩm và query có cùng ngữ nghĩa hay không, kể cả khi dữ liệu không đầy đủ.

Faiss HNSW là lớp serving trên không gian embedding của SCALE. Sau khi SCALE tạo vector biểu diễn, HNSW tìm nhanh các ứng viên gần nhất trên catalog lớn, còn tầng metadata reranking điều chỉnh thứ hạng dựa trên thuộc tính. Sự phân tách này giúp đánh giá rõ chất lượng representation của SCALE và hiệu năng truy hồi của chỉ mục, đồng thời phù hợp hơn với bài toán product retrieval đa ngành hàng so với các hướng chỉ tối ưu image-only hoặc image-text.

IV. PHÁT BIỂU BÀI TOÁN (PROBLEM STATEMENT)

A. Mục tiêu

Giải quyết bài toán **Multimodal Retrieval** trên tập sản phẩm thương mại điện tử. Cho trước một truy vấn q chứa các modality khả dụng và một kho sản phẩm catalog G , hệ thống cần trả về tập hợp Top-K sản phẩm có biểu diễn vector

đa phương thức tương đồng nhất. Mặc dù từng listing có thể bị thiếu hụt một số nhánh thông tin, không gian nhúng được học vẫn phải bảo đảm tính nhất quán để so sánh.

B. Đầu vào và Đầu ra (Input / Output)

1) Đầu vào (Input):

- **Query:** $q = (\text{Image}, \text{Text}, \text{Table}, \text{Video}, \text{Audio})$. Trong đó, Table là bảng thuộc tính cặp key-value; Audio được trích xuất từ Video. Theo phương pháp gốc, audio được biểu diễn bằng MFCC; pipeline hiện tại tạo log mel-spectrogram, do đó hai cấu hình này được tách riêng khi báo cáo thực nghiệm. Query chứa các modality khả dụng, trong đó **bắt buộc phải có tối thiểu Image hoặc Video**, các nhánh còn lại có thể khuyết thiếu.
- **Kho sản phẩm (Catalog):** $G = \{p_1, p_2, \dots, p_N\}$, trong đó mỗi $p_i = (\text{Image}_i, \text{Text}_i, \text{Table}_i, \text{Video}_i, \text{Audio}_i)$ cũng có thể không đầy đủ các modality.

2) Đầu ra (Output):

- Tập hợp K sản phẩm hàng đầu $\{p_1, p_2, \dots, p_K\}$ trích xuất từ catalog G , đi kèm ảnh đại diện, metadata và điểm số tương đồng $\text{sim}(f(q), f(p_i))$ phục vụ hiển thị giao diện và bước tái xếp hạng.

C. Biểu diễn toán học (Formalization)

Ký hiệu $f(\cdot)$ là hàm mã hóa đa phương thức SCALE (bao gồm các encoder riêng biệt cho từng nhánh, cơ chế Zero-Imputation xử lý nhánh thiếu, mạng Joint Co-Transformer và lớp gom tụ Pooling).

Hàm tính độ tương đồng $\text{sim}(\cdot, \cdot)$ được định nghĩa bằng tích vô hướng giữa hai vector đã qua chuẩn hóa L_2 (tương đương với điểm Cosine Similarity):

$$\text{TopK}(q, G) = \arg \max_{p_i \in G}^K \text{sim}(f(q), f(p_i)) \quad (3)$$

Sau quá trình truy hồi thô bằng chỉ mục Faiss HNSW, điểm số tương đồng sim này sẽ kết hợp với điểm tương đồng thuộc tính $S_{\text{thuoc_tin}}$ trước khi cắt ngưỡng lấy Top-K danh sách cuối cùng.

D. Yêu cầu hệ thống

- Học được không gian nhúng giàu ngữ nghĩa từ 5 modality và tự động cân bằng mức độ đóng góp của từng nhánh thông qua cơ chế SIMCL.
- Có khả năng mã hóa các query hoặc catalog mục thiếu modality mà không gây lỗi chương trình hay lệch phân bố vector (thông qua cơ chế Zero Imputation).
- Khả năng truy hồi thời gian thực trên catalog quy mô lớn; hỗ trợ thêm mới listing vào chỉ mục Faiss HNSW mà không cần huấn luyện hay xây dựng lại toàn bộ chỉ mục từ đầu.
- Báo cáo $mAP@K$ và $Prec@K$ ($K \in \{1, 5, 10\}$), đồng thời ghi rõ positive set, split, checkpoint và cấu hình index. Chỉ khi các thành phần này khớp mới được so sánh trực tiếp với quy trình đánh giá của SCALE.

V. CÁC THÁCH THỨC THỰC HIỆN

A. Thách thức 1: Modality Interaction

Làm thế nào để mô hình hóa mối tương tác giữa nhiều modality khi mỗi nhánh chỉ phản ánh một phần thông tin của sản phẩm?

- **Ví dụ:** Xét một sản phẩm gối trên sàn thương mại điện tử: Ảnh thể hiện màu sắc/hình dáng; Text cung cấp thông tin "Gối Memory Foam"; Table lưu trữ kích thước/chất liệu; Video minh họa độ đàn hồi khi ấn; Audio thuyết minh tính năng. Không một modality nào đơn lẻ đủ để đại diện hoàn toàn cho sản phẩm.
- **Cơ chế xử lý:** Mạng SCALE định nghĩa mức độ hỗ trợ ngữ nghĩa giữa hai nhánh thông qua điểm căn chỉnh (alignment score). Trong cơ chế SIMCL, ma trận S học được đóng vai trò là trọng số cho từng cặp hàm mất mát liên-modal (cross-modality loss): giá trị $S(u, v)$ lớn thể hiện hai nhánh u và v bổ sung nhiều ngữ nghĩa cho nhau; ngược lại $S(u, v)$ nhỏ phản ánh hai nhánh ít tương trợ hoặc độc lập. Nếu gán trọng số bằng nhau cho mọi cặp, các nhánh nhiều hoặc ít thông tin sẽ làm lệch biểu diễn chung khi số lượng modality tăng lên.

B. Thách thức 2: Modality Noise

Làm thế nào để tận dụng các mẫu sản phẩm bị khuyết thiếu modality mà không cần phải loại bỏ (discard) dữ liệu?

- **Thực tế:** Trong tập dữ liệu M5Product, khoảng 20% số mẫu không có đủ 5 modality và khoảng 5% là mẫu đơn phương thức (unimodal).
- **Cơ chế xử lý:** Mô hình áp dụng kỹ thuật **Zero Imputation** kết hợp với Attention Mask. Kỹ thuật này giúp đưa các mẫu thiếu vào quá trình huấn luyện và đánh giá một cách bình thường mà không cần xóa bỏ. Việc loại bỏ mẫu thiếu sẽ dẫn tới mất mát dữ liệu nghiêm trọng và giảm khả năng tổng quát hóa của mô hình trên dữ liệu thực tế.

C. Thách thức bổ sung: Nhiễu trên ảnh sản phẩm (Visual Noise)

Hình ảnh listing trên sàn e-commerce thực tế không phải là vật thể sạch trên nền trắng mà chứa rất nhiều thành phần nhiễu:

- 1) **Nhiễu do văn bản đè (Text Overlay):** Các biểu ngữ quảng cáo, thông tin khuyến mại ("Giảm 50%", "Giao nhanh 2h"), watermark, logo shop đè trực tiếp lên bề mặt sản phẩm.
- 2) **Nhiễu do biến thể sản phẩm đi kèm:** Một bức ảnh chứa nhiều phiên bản kích thước/dung tích khác nhau (ví dụ: bộ chai gel rửa tay đủ dung tích 100ml, 250ml, 500ml) gây nhầm lẫn giữa truy hồi cấp độ thể hiện (instance-level) và cấp độ danh mục (category-level).
- 3) **Nhiễu do vật thể phụ/người mẫu:** Xuất hiện bàn tay người đeo vòng, cạp trang điểm đi kèm set mỹ phẩm, hộp quà tặng,...

Giải pháp: Sử dụng đặc trưng vùng (Region Features) trích xuất từ Faster R-CNN. Pipeline hiện tại chuẩn hóa mỗi ảnh về 36 slot region để tập trung vào các vùng chi tiết sản phẩm thay vì mã hóa toàn bộ khung hình chứa banner quảng cáo.

D. Ràng buộc vận hành: Catalog lớn và dữ liệu động

Phương pháp tìm kiếm tuyến tính (Exact Search) không thể đáp ứng được thời gian phản hồi thực tế khi catalog mở rộng lên hàng triệu SKU. Do các listing mới liên tục được đăng bán, cấu trúc chỉ mục (indexing) phải cho phép chèn thêm vector mới vào đồ thị đa tầng (HNSW) một cách trực tiếp mà không cần huấn luyện lại hay rebuild toàn bộ chỉ mục từ đầu.

VI. PHƯƠNG PHÁP ĐỀ XUẤT

A. Kiến trúc tổng thể




Figure 2. Pipeline SCALE + Faiss HNSW. Offline, catalog được mã hóa và lập chỉ mục; online, query được mã hóa, truy hồi N ứng viên và tái xếp hạng trước khi trả về Top- K .

Pipeline gồm hai lớp chính: SCALE tạo unified embedding từ năm modality, còn Faiss HNSW lọc thô ứng viên và metadata reranking điều chỉnh thứ hạng cuối cùng.

B. Kiến trúc SCALE

SCALE sử dụng năm encoder cho image, text, table, video và audio. Các token được kết hợp vào Joint Co-Transformer. Kiến trúc gồm các unimodal encoder và fusion encoder, mỗi phần sử dụng sáu transformer layers với hidden size 768 [?]. Các đoạn sau lần lượt đối chiếu phương pháp gốc với cấu hình triển khai hiện tại của từng modality.

1) *Image: region features từ Faster R-CNN*: Theo M5Product-SCALE, nhánh ảnh không đưa toàn bộ ảnh vào JCT như một tensor pixel duy nhất mà dùng region feature của Faster R-CNN ResNet-101 pretrained trên Visual Genome [?], [?]. Từ các proposal có xác suất phát hiện lớp cao, mô hình chọn 10–36 bounding box cho mỗi ảnh. Số lượng biến thiên là cần thiết: ảnh đơn giản có thể chỉ cần vài vùng có ý nghĩa, trong khi ảnh sản phẩm chứa nhiều chi tiết cần nhiều proposal hơn. Mỗi region đi kèm tọa độ hộp và đặc trưng thị giác, nhờ đó JCT có thể tập trung vào logo, vật liệu hoặc bộ phận sản phẩm thay vì background.

Trong pipeline của đề tài, extractor dùng Detectron2 với Faster R-CNN ResNet-101 C4 và trọng số Visual Genome. Đầu ra được chuẩn hóa thành đúng 36 slot: nếu detector trả về $r < 36$ vùng thì các vị trí còn lại được zero-pad và attention

mask phân biệt padding với vùng thật; nếu nhiều hơn thì chỉ giữ 36 vùng điểm cao nhất. Đây là lựa chọn triển khai để tensor có kích thước cố định, không phải thay đổi phương pháp của paper.

2) *Text: BERT cho tiêu đề và caption*: Paper dùng BERT để khởi tạo text transformer, còn các transformer của modality khác được khởi tạo ngẫu nhiên. Caption được cắt ở 36 token, bao gồm token biên, để giữ chi phí self-attention thấp nhưng vẫn đủ cho title/caption ngắn của listing. BERT được chọn thay vì sentence encoder, CLIP text encoder hoặc LLM vì SCALE cần token-level representation cho MLM, attention xuyên modality trong JCT và hidden size 768 tương thích trực tiếp với backbone. Thay encoder mà không pretrain/fine-tune lại sẽ làm lệch không gian embedding và các masked task.

Source của đề tài dùng bert-base-chinese, một lựa chọn phù hợp với checkpoint và dữ liệu thương mại điện tử tiếng Trung của M5Product. Vì vậy, cấu hình này không nên được diễn giải là lựa chọn tối ưu cho truy vấn tiếng Việt; triển khai tiếng Việt cần dùng BERT đa ngôn ngữ hoặc mô hình tiếng Việt tương thích, sau đó huấn luyện lại các nhánh liên quan.

3) *Table: thuộc tính có cấu trúc*: Paper dùng một transformer riêng để mã hóa table, tách biệt với text transformer, và đặt chiều dài tối đa là 64 token. Table biểu diễn các cặp thuộc tính–giá trị như brand, material, color hoặc size. Trong bước chuẩn bị của đề tài, mỗi cặp được tuần tự hóa theo khuôn dạng entity–value để mô hình phân biệt rõ tên thuộc tính với giá trị. Cách biểu diễn này giữ được thông tin fine-grained mà caption thường bỏ sót; Masked Entity Modeling che cả một entity hoặc value để JCT suy luận lại từ phần table còn lại và các modality khác. Vì vậy, table đặc biệt hữu ích để phân biệt các SKU nhìn gần giống nhưng khác model, thông số hoặc thương hiệu.

4) *Video: chuỗi khung hình ngắn*: Theo paper, video gốc có tốc độ 24 FPS và chỉ lấy một frame mỗi giây để giảm thông tin dư thừa giữa các frame liên kề. Các ordinal frame này được đưa vào video encoder, sau đó tham gia JCT cùng các modality khác. Lấy mẫu theo thời gian thay vì chỉ lấy frame đầu giúp biểu diễn được nhiều góc nhìn, thao tác sử dụng hoặc trạng thái sản phẩm trong video dài.

Source hiện tại khác cấu hình paper: bộ trích xuất dùng tối đa 12 frame đầu theo thứ tự giải mã, thu nhỏ cạnh dài tối đa 480 pixel, đưa từng frame qua ResNet-50 và chuẩn hóa đầu ra về 1024 chiều; frame thiếu được zero-pad. Đây là cấu hình gọn nhẹ để tạo sidecar video trên Windows, nhưng 12 frame đầu có thể chưa bao quát toàn bộ video. Lấy mẫu đều 1 FPS và dùng video encoder như paper là hướng cải thiện cần thiết.

5) *Audio: mel-spectrogram từ 12 giây đầu*: Theo paper, audio được trích xuất từ các frame video đã chọn rồi chuyển thành đặc trưng MFCC, với frame size 1024 và hop size 256. MFCC nén phổ âm thanh theo thang Mel và phù hợp cho audio encoder cùng Masked Audio Modeling; nhánh này có thể mang thông tin từ lời thuyết minh, nhạc nền hoặc âm thanh thao tác sản phẩm. Với listing không có audio, zero imputation và attention mask giúp mô hình không diễn giải phần đệm là tín hiệu thực.




Figure 3. Tổng quan kiến trúc SCALE: các encoder đơn phương thức được kết hợp bằng JCT, các masked tasks và SIMCL để hỗ trợ các tác vụ downstream.

Table IV
ĐỐI CHIẾU TIỀN XỬ LÝ MODALITY: M5PRODUCT-SCALE VÀ SOURCE HIỆN TẠI

Modality	M5Product-SCALE	Source hiện tại
Image	Faster R-CNN ResNet-101 trên Visual Genome; 10–36 region	Detectron2 Faster R-CNN R101 C4; chuẩn hóa 36 slot
Text	BERT; caption tối đa 36 token	bert-base-chinese; tối đa 36 token
Table	Transformer riêng; tối đa 64 token	Entity-value; tối đa 64 token
Video	Video 24 FPS, lấy 1 frame/giây	Tối đa 12 frame đầu; ResNet-50, 1024 chiều
Audio	MFCC; frame/hop 1024/256	Log mel 16 kHz, 80×751; FFT/hop 1024/256

Source hiện tại dùng một biến thể gần với tiền xử lý phổ âm thanh: audio mono 16 kHz được cắt hoặc zero-pad thành 12 giây, sau đó tạo log mel-spectrogram 80 mel bins với FFT 1024, hop length 256 và chuẩn hóa theo từng mel bin, cho tensor 80×751 . Đây là khác biệt triển khai cần được báo cáo tách biệt với MFCC của paper khi so sánh kết quả.

Bảng ?? cho thấy text và table giữ đúng giới hạn chuỗi của paper, trong khi image, video và audio có khác biệt ở bước trích xuất đặc trưng. Vì vậy, chỉ kết quả chạy với pipeline khớp cấu hình cột giữa mới nên được so sánh trực tiếp với các chỉ số công bố của SCALE. Các thay đổi tiền xử lý này có thể ảnh hưởng đến kết quả truy hồi cuối cùng; ảnh hưởng cụ thể được trình bày trong phần kết quả và đánh giá thực nghiệm.

C. Joint Co-Transformer

JCT là tầng hợp nhất thông tin trung tâm của SCALE. Sau các encoder riêng, mỗi modality cho một dãy token ở cùng không gian ẩn 768 chiều: T_I (region ảnh), T_T (caption), T_{Tab} (entity-value), T_V (frame video) và T_A (đặc trưng audio). Với một listing thiếu modality, dãy token tương ứng được zero-impute và những vị trí đệm được đánh dấu bởi attention mask.

Theo thiết kế SCALE, các dãy này không bị gộp trung bình ngay từ đầu mà được giữ ở mức token để mô hình còn có thể liên kết chi tiết giữa các modality [?].

1) *Bước 1: tự chú ý trong từng modality*: Trước khi fusion, encoder riêng của mỗi modality thực hiện multi-head self-attention trên chính dãy token của modality đó. Với X_m là embedding của modality m , mỗi head tạo query, key và value rồi tính:

$$A_m^{\text{self}} = \text{softmax} \left(\frac{(X_m W_m^Q)(X_m W_m^K)^\top}{\sqrt{d_h}} + M_m \right), \quad (4)$$

$$Z_m = A_m^{\text{self}}(X_m W_m^V).$$

M_m che token padding hoặc modality không có dữ liệu. Bước này giúp region ảnh chọn các region ảnh liên quan khác, caption liên hệ giữa các từ, còn table/video/audio học cấu trúc nội bộ trước khi nhận tín hiệu từ nguồn khác. Mỗi khối attention được theo sau bởi residual connection, layer normalization và feed-forward network (FFN), nhờ đó đặc trưng vừa được trộn ngữ cảnh vừa giữ thông tin ban đầu.

2) *Bước 2: nối token và chú ý chéo giữa modality*: Các dãy đã mã hóa được nối thành một chuỗi chung

$$X = [Z_T; Z_{Tab}; Z_I; Z_V; Z_A], \quad H = \text{JCT}(X, M), \quad (5)$$

trong đó M là mask ghép từ năm modality. Trong JCT, self-attention được áp dụng trên toàn bộ X . Vì vậy, ma trận attention có các block đường chéo $A_{m,m}$ biểu diễn self-attention nội bộ và các block ngoài đường chéo $A_{m,n}$, $m \neq n$, biểu diễn cross-attention giữa hai modality:

$$A_{m,n} = \text{softmax} \left(\frac{(Z_m W^Q)(Z_n W^K)^\top}{\sqrt{d_h}} + M_{m,n} \right), \quad (6)$$

$$C_m = \sum_n A_{m,n}(Z_n W^V).$$

Nói cách khác, query của một token ảnh có thể lấy value từ token caption hoặc table; ngược lại, token text có thể tập

trung vào region ảnh, frame video hay audio phù hợp. Ví dụ, token “leather” có thể tăng attention lên region thể hiện chất liệu da, còn token màu sắc trong table có thể điều chỉnh cách mô hình đọc ảnh sản phẩm. FFN sau attention biến đổi từng token độc lập; residual connection giữ đường truyền ổn định qua các lớp. Sau lớp JCT cuối, các dãy được tách trở lại theo ranh giới modality, pool từ token đầu mỗi dãy và kết hợp thành biểu diễn listing phục vụ masked tasks, SIMCL và retrieval.

D. Học đa phương thức với cơ chế Mask (Masked Multimodal Learning)

Masked Multimodal Learning là nhóm pretext task tự giám sát được áp dụng sau JCT. Mục tiêu không phải là dự đoán nhãn danh mục, mà buộc biểu diễn fusion phải khôi phục phần thông tin bị che từ ngữ cảnh còn lại. Với mỗi modality, SCALE che ngẫu nhiên 15% đầu vào; phần không bị che trong cùng modality và các modality khác của cùng listing là nguồn ngữ cảnh để tái tạo [?]. Hàm mất mát của modality i được viết:

$$L_{M_i}(\theta) = -\mathbb{E} \log P_{\theta}(t_{\text{mask}} | t_{\neg \text{mask}}, M_{\neg i}). \quad (7)$$

Trong đó, t_{mask} là token hoặc feature bị che, $t_{\neg \text{mask}}$ là phần chưa che của chính modality i , còn $M_{\neg i}$ là các modality còn lại. Vì dự đoán diễn ra sau JCT, mô hình chỉ giảm loss tốt khi đồng thời học được cấu trúc nội bộ và quan hệ liên modality, thay vì chỉ sao chép tín hiệu cục bộ.

1) *Phần bị che không phải là modality bị thiếu*: Masking là nhiễu nhân tạo, được tạo mới cho từng mẫu trong lúc pretraining; phần dữ liệu gốc không bị xóa khỏi dataset mà được lưu riêng làm target để tính loss. Vị trí bị che vẫn giữ nguyên vị trí trong dãy token và vẫn có attention mask bằng 1, nên JCT biết rằng đó là một vị trí hợp lệ nhưng không được quan sát nội dung gốc. Điều này khác với modality thật sự không tồn tại trong listing: khi đó input được zero-impute và attention mask bằng 0 để mô hình bỏ qua toàn bộ nhánh vắng mặt.

Ở hiện thực của đề tài, cách thay thế nội dung bị che phụ thuộc vào modality. Với text, 15% token được chọn; trong số này 80% đổi thành [MASK], 10% đổi thành token ngẫu nhiên và 10% giữ nguyên token gốc nhưng vẫn phải dự đoán lại. Với image region, 15% region được chọn, trong đó 90% feature bị thay bằng vector 0 còn 10% được giữ nguyên để tránh mô hình chỉ phụ thuộc vào một ký hiệu mask. Video và audio thay feature của vị trí được chọn bằng vector 0. Với table, MEM chọn ngẫu nhiên một phía của cặp property–value và thay toàn bộ token của phía đó bằng [MASK]; phía còn lại cùng các modality khác trở thành ngữ cảnh để khôi phục. Trong mọi trường hợp, target luôn là token hoặc feature gốc trước khi thay thế.

2) Các masked task theo modality:

- **MLM (text)**: che từng word/subword trong caption và dự đoán lại token đó. Nhiệm vụ này duy trì ngữ nghĩa câu, đồng thời cho phép từ bị che nhận tín hiệu từ ảnh hoặc table.
- **MRP (image)**: che region feature và dự đoán feature vùng ảnh tương ứng. Nhờ đó, một region bị che có thể được suy luận từ các region còn lại và mô tả sản phẩm.

- **MEM (table)**: che toàn bộ một entity thuộc tính, chẳng hạn brand, material hoặc color, thay vì che rời rạc từng subword. Đây là điểm quan trọng vì table chứa các cặp key–value có cấu trúc; che cả entity ép mô hình khai thác quan hệ với value và các modality khác.
- **MFP (video)**: che feature của frame được lấy mẫu và tái tạo từ các frame lân cận cùng thông tin text/image/table.
- **MAM (audio)**: che một phần đặc trưng audio và dự đoán lại từ ngữ cảnh audio còn lại cũng như các modality đồng thời xuất hiện.

Nhấn mục tiêu của các task trên là nội dung hoặc feature gốc của phần bị che. Cách đặt bài toán chung này giúp các modality có bản chất khác nhau cùng đóng góp vào một representation space, đồng thời phù hợp với trường hợp listing thiếu modality vì attention mask ngăn JCT coi vector đệm là tín hiệu quan sát được.

E. Thuật toán SIMCL

SIMCL (Self-harmonized Inter-Modality Contrastive Learning) là thành phần căn chỉnh ngữ nghĩa giữa các modality. Với minibatch $D \in \mathbb{R}^{B \times M \times F}$, trong đó B là batch size, M là số modality và F là chiều embedding, SCALE xét từng cặp modality m, n . Hai embedding $f_b^{(m)}$ và $f_b^{(n)}$ của cùng listing b tạo thành một positive pair; embedding của listing khác trong batch tạo thành negative pairs. Với mỗi positive pair, có $2(B-1)$ negative pairs khi xét theo hai chiều modality.

Đặt $s_{b,r}^{m,u} = \exp(\text{sim}(f_b^{(m)}, f_r^{(u)})/\tau)$. Loss contrastive cho một cặp modality có dạng InfoNCE:

$$L_{m,n}^{CL} = -\log \frac{s_{b,b}^{m,n}}{s_{b,b}^{m,n} + \sum_{r \neq b} \sum_{u \in \{m,n\}} s_{b,r}^{m,u}}. \quad (8)$$

trong đó sim là cosine similarity và τ là temperature. Loss kéo các modality của cùng sản phẩm lại gần nhau, đồng thời đẩy chúng xa biểu diễn của sản phẩm khác. Tuy nhiên, không phải cặp modality nào cũng hỗ trợ như nhau: image–text thường có thể hỗ trợ mạnh, trong khi audio nhiều hoặc modality thiếu không nên nhận cùng trọng số.

1) *Tự điều hòa bằng ma trận alignment*: Để xử lý bài toán nhiều hơn hai modality, SCALE học ma trận alignment $S \in \mathbb{R}^{M \times M}$ cho từng sample. S được khởi tạo từ ma trận 0 và tối ưu cùng mô hình; softmax biến các giá trị tự do thành trọng số tương đối, sau đó paper dùng phép tự điều hòa:

$$\hat{S} = S \odot \text{softmax}(S). \quad (9)$$

Các phần tử tam giác trên $\hat{S}_{m,n}^{\Delta}$ cân trọng số loss contrastive liên modality; phần tử đường chéo $\hat{S}_m^{\text{diag}}$ cân loss masked của từng modality. Tổng loss là:

$$L_{\text{total}} = \sum_{m < n} \hat{S}_{m,n}^{\Delta} L_{m,n}^{CL} + \sum_m \hat{S}_m^{\text{diag}} L_{M_m}. \quad (10)$$

Cơ chế này khiến masked learning và contrastive learning không cạnh tranh theo trọng số cố định: mô hình tự tăng đóng góp của cặp modality có tính hỗ trợ cao, đồng thời giảm ảnh hưởng của cặp ít thông tin hoặc nhiễu. Hình ?? minh họa quá




Figure 4. Minh họa SIMCL: các cặp cùng product tạo positive pairs, các product khác tạo negatives; ma trận inter-modality scores điều chỉnh mức đóng góp của từng cặp modality.

trình tạo positive/negative pairs và dùng inter-modality scores để điều hòa từng loss.

F. Xử lý thiếu Modality (Missing Modality)

Nếu một listing thiếu modality, SCALE không loại bỏ sample mà sử dụng zero imputation và attention mask. Điều này giúp mô hình vẫn học từ các listing không hoàn chỉnh và giảm ảnh hưởng của nhánh zero khi tạo embedding.

Embedding cuối cùng trong triển khai được tạo từ các pooled representation khả dụng:

$$e = t + p + i + v + a, \quad (11)$$

sau đó được L2-normalize trước retrieval.

G. Cách SCALE giải quyết hai thách thức trung tâm

1) Giải quyết Thách thức Modality Interaction:

- **Kiến trúc JCT một luồng:** Nối chuỗi (concatenate) toàn bộ các token đến từ cả 5 nhánh (Image, Text, Table, Video, Audio) vào chung một khối Transformer 6 lớp. Cấu trúc này cho phép cơ chế Self-Attention hoạt động tự do trong nội bộ từng nhánh (intra-modality) lẫn xuyên suốt giữa các nhánh với nhau (cross-modality).
- **Ma trận cân chỉnh linh hoạt (SIMCL Alignment Matrix S):** Thay vì gán trọng số cố định cho mọi cặp loss liên-modality, cơ chế SIMCL khởi tạo và học một ma trận trọng số $S \in \mathbb{R}^{5 \times 5}$. Thông qua hàm Softmax, ma trận này tự động gán trọng số cao hơn cho các cặp modality hỗ trợ mạnh cho nhau, đồng thời hạ thấp tầm ảnh hưởng của các cặp chứa ít thông tin hoặc chứa nhiễu.

2) Giải quyết Thách thức Modality Noise (Dữ liệu không toàn vẹn):

- **Zero Imputation:** Đối với các nhánh bị khuyết thiếu trên listing, hệ thống tự động lấp đầy (fill) các vector đầu vào bằng vector 0 (zero vector), đồng thời thiết lập các vị trí Attention Mask tương ứng bằng 0.
- **Học thông qua Masked Multi-modal Pretext Tasks:** Việc duy trì các mẫu thiếu trong batch huấn luyện kết

hợp với các nhiệm vụ học tự giám sát (MLM, MRP, MEM, MFP, MAM) ép mô hình phải khai thác thông tin từ các modality khả dụng còn lại để khôi phục đặc trưng bị khuyết. Đồng thời, ma trận S trong SIMCL cũng tự động suy giảm trọng số đối với các nhánh bị zero-impute, tránh làm lệch giá trị của hàm mất mát tổng thể.

VII. TRUY HỒI HIỆU NĂNG CAO VỚI FAISS HNSW

Faiss được chọn làm tầng truy hồi vì đây là thư viện chuyên dụng cho tìm kiếm tương tự trên vector dense, hỗ trợ cả exact search để đánh giá representation và approximate nearest-neighbor search để phục vụ catalog lớn [?]. Sau khi SCALE biến mỗi listing thành một embedding đã L2-normalize, bài toán online trở thành tìm các vector có inner product/cosine similarity lớn nhất. Thực hiện phép so sánh với toàn bộ catalog ở mỗi truy vấn có chi phí tuyến tính theo số listing và nhanh chóng trở thành nút thắt khi catalog tăng quy mô. Faiss cung cấp index tối ưu cho tác vụ này, có thể lưu vector, thực hiện truy vấn batch và tách lớp truy hồi khỏi representation backbone; nhờ đó có thể thay đổi hoặc cập nhật index mà không phải huấn luyện lại SCALE.

SCALE trong bài báo gốc sử dụng exact inner-product retrieval. Tuy nhiên, exact search có chi phí tăng tuyến tính theo số lượng listing. Đối với catalog lớn và cập nhật thường xuyên, đề tài bổ sung Faiss HNSW [?], [?].

HNSW xây dựng đồ thị nhiều tầng cho approximate nearest-neighbor search. Các tham số chính gồm M , $efConstruction$ và $efSearch$. Listing mới có thể được thêm vào index mà không cần huấn luyện một IVF index mới.

Quy trình online là:

- 1) Nhận multimodal query.
- 2) Preprocess và encode bằng SCALE.
- 3) L2-normalize query embedding.
- 4) Tìm N ứng viên bằng HNSW, với $N > K$.
- 5) Tính điểm reranking trên metadata.
- 6) Sắp xếp lại và trả về K listing.

HNSW chỉ là lớp serving của đề tài; các số liệu dùng để so sánh trực tiếp với paper SCALE vẫn giữ exact-retrieval protocol.

VIII. TÁI XẾP HẠNG DỰA TRÊN THUỘC TÍNH (ATTRIBUTE-AWARE RERANKING)

A. Động lực và Hạn chế của Retrieval Thuần Embedding

Embedding similarity (S_{emb}) thu được từ không gian ẩn của SCALE đóng vai trò rất tốt trong việc bắt các đặc trưng tổng thể. Tuy nhiên, phương pháp retrieval thuần embedding gặp phải ba hạn chế cốt lõi trong thực tế thương mại điện tử:

- 1) **Hiện tượng trùng lặp đặc trưng thị giác khác ngành:** Các sản phẩm thuộc các danh mục hoàn toàn khác nhau có thể sở hữu vẻ ngoài tương đồng (ví dụ: một chiếc ốp điện thoại hình bao da có hoa văn chất liệu da rất dễ có vector embedding gần với một chiếc ví cầm tay da).
- 2) **Nhiều nền và thành phần phụ:** Ảnh sản phẩm e-commerce thường chứa chữ quảng cáo, logo thương hiệu,

watermark hoặc mẫu nhân vật (model). Điều này khiến vector embedding bị lệch khỏi đối tượng chính.

- 3) **Bổ sót thuộc tính quyết định:** Độ tương đồng vector chỉ phản ánh sự “gần giống”, nhưng giao dịch e-commerce yêu cầu sự “chính xác tuyệt đối” về các thuộc tính cứng như thương hiệu (Brand), siêu danh mục (Super-category) hoặc danh mục chi tiết (Category).

Để khắc phục các điểm yếu trên, tăng tái xếp hạng dựa trên thuộc tính được tích hợp ngay sau bước lọc thô của Faiss HNSW, đóng vai trò như một bộ lọc tinh nhằm điều chỉnh điểm số dựa trên thông tin thuộc tính cấu trúc.

B. Tái xếp hạng cho Truy vấn Đa phương thức có Thuộc tính (Multimodal Query với Text/Table)

Khi truy vấn q chứa thông tin văn bản hoặc bảng thuộc tính (từ người dùng nhập hoặc trích xuất trực tiếp), hệ thống thực hiện so khớp thuộc tính cứng giữa query và ứng viên thứ i trong tập N ứng viên:

$$S_{\text{attr}}(q, p_i) = \alpha \cdot I(SD_q = SD_{p_i}) + \beta \cdot I(D_q = D_{p_i}) + \gamma \cdot \text{Jaccard}(S_q, S_{p_i}), \quad (12)$$

trong đó:

- SD_q, SD_{p_i} lần lượt là siêu danh mục (Super-category) của query và ứng viên p_i .
- D_q, D_{p_i} là danh mục chi tiết (Category) của query và ứng viên p_i .
- S_q, S_{p_i} là tập các cặp thuộc tính-giá trị (ví dụ: {thương hiệu: Nike, chất liệu: da}). Hàm $\text{Jaccard}(S_q, S_{p_i}) = \frac{|S_q \cap S_{p_i}|}{|S_q \cup S_{p_i}|}$ đo mức độ trùng khớp các thông số kỹ thuật.
- $I(\cdot)$ là hàm chỉ thị (Indicator function), trả về 1 nếu điều kiện đúng và 0 nếu sai.
- α, β, γ là các hệ số trọng số thỏa mãn $\alpha + \beta + \gamma = 1$, với ưu tiên $\alpha > \beta$ để phạt nặng các sản phẩm sai lệch hẵn về ngành hàng lớn.

C. Tái xếp hạng cho Truy vấn Chỉ chứa Ảnh (Image-only Query)

Đối với các truy vấn người dùng chỉ cung cấp hình ảnh (Image-only query), hệ thống không có sẵn thông tin thuộc tính văn bản nhập vào. Để giải quyết vấn đề này, phương pháp đề xuất áp dụng cơ chế phản hồi độ liên quan giả định (Pseudo Relevance Feedback - PRF) trên tập N ứng viên ban đầu trả về từ Faiss HNSW:

- 1) **Suy luận nhãn đa số (Majority Voting):** Trích xuất danh mục của N ứng viên top đầu. Xác định siêu danh mục đa số SD^* và danh mục/thương hiệu đa số D^* chiếm tỷ lệ xuất hiện cao nhất trong tập ứng viên.
- 2) **Tính điểm thuộc tính suy luận:**

$$S_{\text{attr}}(q, p_i) = \alpha \cdot I(SD_{p_i} = SD^*) + \beta \cdot I(D_{p_i} = D^*). \quad (13)$$

Chiến lược bầu chọn đa số giúp giảm thiểu rủi ro so với việc lấy nhãn của duy nhất ứng viên Top-1 (vốn có thể bị nhiễu thị giác dẫn đến dự đoán sai). Tuy nhiên, trong trường hợp bước lọc thô HNSW bị lệch hoàn toàn (ví dụ: hơn 50%

Table V
CẤU HÌNH CHÍNH

Thành phần	Thiết lập
Tập dữ liệu	M5Product subset
Số lượng mẫu	10,000
Phân bố	70/20/10
Kiến trúc	SCALE
Hidden size	768
Độ dài Văn bản	36
Độ dài Bảng	64
Vùng ảnh (Paper / source)	10–36 region / 36 slot cố định
Video (Paper / source)	1 frame/giây từ 24 FPS / 12 frame đầu, ResNet-50
Audio (Paper / source)	MFCC / log mel-spectrogram (80 × 751)
Tỷ lệ Masking	15%
Số epoch (bài báo gốc)	5 epochs
Số epoch (pipeline dự kiến)	10 epochs
Bộ tối ưu	Adam
Learning rate (Gốc)	10^{-4}
Phần cứng (Gốc)	4 GPUs

tập N ứng viên trả về sai ngành hàng), phương pháp PRF có thể bị khuếch đại lỗi—đây là một trường hợp thất bại (failure case) cần được cân nhắc.

D. Hàm Điểm Tổng hợp và Điều chỉnh Miền

Điểm số cuối cùng dùng để sắp xếp lại danh sách kết quả trước khi cắt lấy Top- K được tính theo công thức kết hợp tuyến tính:

$$S_{\text{total}}(q, p_i) = \lambda \cdot S_{\text{emb}}(q, p_i) + (1 - \lambda) \cdot S_{\text{attr}}(q, p_i), \quad (14)$$

với $0 \leq \lambda \leq 1$ là tham số điều phối tầm quan trọng giữa độ tương đồng vector và độ tương đồng thuộc tính.

Tham số λ được điều chỉnh linh hoạt theo miền sản phẩm:

- **Miền thời trang:** Yếu tố kiểu dáng, màu sắc và thẩm mỹ thị giác đóng vai trò quyết định. Do đó, λ được thiết lập cao ($\lambda \geq 0.7$) để ưu tiên độ tương đồng vector S_{emb} .
- **Miền thiết bị số / Điện máy:** Các thuộc tính cứng (dung lượng RAM, thương hiệu, mã model) quyết định tính đúng đắn của sản phẩm. Hệ thống sẽ giảm λ ($\lambda \leq 0.4$) để tăng trọng số cho S_{attr} , tránh việc trả về sản phẩm khác model dù có hình thức giống hệt.

IX. THIẾT LẬP THỰC NGHIỆM

A. Cấu hình huấn luyện

Các cấu hình trong Bảng ?? mô tả pipeline thiết kế. Kết quả thực nghiệm hiện có chỉ lưu các metric của đặc trưng năm modality; vì vậy chúng không đủ để khẳng định checkpoint, seed, số mẫu thực tế hay tham số HNSW. Các thông tin này cần được lưu kèm mỗi lần chạy để bảo đảm tái lập.

B. Đánh giá truy hồi (Retrieval Evaluation)

Để so sánh trực tiếp với kết quả SCALE, cần giữ nguyên pipeline gốc:

- 1) Trích xuất pooled embeddings;
- 2) Tính exact score $q^T G$;
- 3) Loại query khỏi ranking;
- 4) Lấy tối đa 10 kết quả;
- 5) Đánh giá với ground truth category.

Các metric chính là mAP@1, mAP@5, mAP@10 và Precision@1, Precision@5, Precision@10. Mỗi lần chạy phải lưu cách xác định positive set và công thức AP. Với tập con tự tạo, positive set theo nhãn nội bộ không phải ground truth chính thức của M5Product; do đó không được đặt hai loại kết quả trên cùng một thang so sánh.

HNSW, latency, QPS, recall so với FlatIP và thời gian thêm listing cần được đánh giá riêng như system-level metrics, không trộn với bảng representation của SCALE.

X. KẾT QUẢ VÀ ĐÁNH GIÁ THỰC NGHIỆM

A. Kết quả tham chiếu từ SCALE

Bảng ?? trình bày các số liệu tham chiếu được báo cáo trong tài liệu SCALE trên subset của M5Product. Mỗi cặp là pretrain/finetune.

Trên subset được báo cáo trong tài liệu gốc, việc bổ sung modality nhìn chung cải thiện Accuracy và retrieval metrics. Năm modality đạt Accuracy 85.50 và mAP@1 58.72/70.62.

B. Kết quả thực nghiệm hiện có

Các kết quả thực nghiệm hiện có ghi nhận metric của đặc trưng năm modality trước và sau cấu hình cải tiến. Bảng ?? chuyển các giá trị từ tỉ lệ phần trăm sang dạng dễ đọc. Cột Δ là chênh lệch điểm phần trăm, không phải phần trăm tăng tương đối.

Ở $K = 10$, cấu hình cải tiến tăng mAP thêm 10.43 điểm phần trăm (xấp xỉ 2.65 lần) và Precision thêm 5.11 điểm phần trăm (xấp xỉ 2.44 lần). Xu hướng này lặp lại tại $K = 1, 5$ và 10, cho thấy thứ hạng đầu danh sách đã được cải thiện chứ không chỉ thay đổi ở một ngưỡng cắt.

1) *Vì sao cấu hình cải tiến có kết quả tốt hơn:* Về mặt cơ chế, cải tiến tác động vào hai điểm dễ gây sai lệch trong product retrieval. Thứ nhất, HNSW thu hẹp catalog thành tập ứng viên gần trong không gian embedding, nên tầng sau chỉ cần phân biệt các sản phẩm thực sự cạnh tranh về ngữ nghĩa. Thứ hai, metadata reranking cộng thêm tín hiệu siêu danh mục, danh mục và thuộc tính vào điểm embedding. Các tín hiệu này đặc biệt hữu ích khi nhiều listing có ảnh gần giống về màu sắc, texture hoặc bố cục nhưng không cùng ngành hàng hay không cùng model. Với query chỉ có ảnh, bầu chọn thuộc tính từ tập ứng viên ban đầu còn tạo một prior về ngành hàng trước khi sắp xếp lại.

Do đó, việc mAP tăng cho thấy positive item xuất hiện sớm hơn trong danh sách; Precision tăng cho thấy Top- K chứa ít candidate sai hơn. Hai chuyển biến này phù hợp với kỳ vọng của reranking: representation của SCALE cung cấp tập ứng viên có liên quan về ngữ nghĩa, còn thuộc tính cấu trúc loại

bớt các item chỉ giống về thị giác. Tuy nhiên, các số liệu đã lưu không kèm split, số query, seed, định nghĩa positive, tham số $N, \alpha, \beta, \gamma, \lambda$ hay latency. Vì vậy, chúng chỉ cho thấy toàn bộ cấu hình cải tiến tốt hơn baseline trong lần đánh giá đã lưu; chưa đủ để quy kết độc lập mức tăng cho HNSW, bầu chọn đa số hoặc từng trọng số reranking.

2) *Vì sao metric nội bộ thấp hơn kết quả công bố:* Không nên so sánh trực tiếp Bảng ?? với kết quả SCALE trong paper như hai benchmark đồng nhất. Paper huấn luyện SCALE trên M5Product quy mô lớn, sử dụng protocol, positive definition, pretraining và fine-tuning riêng [?]; trong khi thí nghiệm nội bộ dùng subset 10,000 mẫu được chia 70/20/10. Subset nhỏ làm giảm độ đa dạng category, số biến thể của cùng sản phẩm và số positive/negative quan sát trong huấn luyện, đồng thời làm metric nhạy hơn với từng query và seed. Phân bố sau lấy mẫu, cách tạo gallery/query và cách xác định cùng sản phẩm cũng có thể khác protocol coarse- hoặc fine-grained retrieval của paper.

3) *Ảnh hưởng của pipeline hiện thực:* Khác biệt hiện thực ảnh hưởng trực tiếp đến distribution của feature mà SCALE nhìn thấy. Ở nhánh ảnh, pipeline luôn đưa 36 region vào encoder. Cấu hình này giúp tensor có kích thước cố định và thuận lợi cho batch processing, nhưng khác với việc paper chọn linh hoạt 10–36 proposal có độ tin cậy cao. Khi ảnh chỉ có ít vùng sản phẩm có ý nghĩa, các slot còn lại là padding; ngược lại, ảnh phức tạp có thể có nhiều proposal hợp lệ nhưng chỉ 36 vùng điểm cao nhất được giữ lại. Vì vậy, chất lượng region feature và attention mask trở nên rất nhạy với detector cũng như đặc điểm ảnh thương mại điện tử có chữ quảng cáo, logo hoặc nhiều sản phẩm trong cùng khung hình.

Khác biệt rõ hơn nằm ở tín hiệu thời gian. Paper lấy mẫu đều một frame mỗi giây từ video 24 FPS để bao phủ toàn bộ diễn tiến, còn pipeline hiện tại dùng tối đa 12 frame đầu theo thứ tự giải mã. Nếu phần giới thiệu, thao tác sử dụng hoặc góc quay quan trọng nằm ở nửa sau video, representation video hiện tại không quan sát được tín hiệu đó. Tương tự, log mel-spectrogram giữ năng lượng theo các dải tần Mel, trong khi MFCC nén phổ theo hệ số cepstral. Hai biểu diễn có kích thước và phân bố khác nhau; do đó audio encoder hoặc masked-audio head được huấn luyện theo một cách biểu diễn không thể được xem là tương đương trực tiếp với cấu hình MFCC của paper.

4) *Giới hạn đánh giá end-to-end:* Để metric phản ánh đúng năng lực SCALE, query mới và catalog phải được mã hóa bởi cùng checkpoint, cùng tiền xử lý và cùng không gian embedding. Rà soát hiện thực cho thấy nhánh encoder hiện có có thể tái sử dụng embedding đã lưu khi title khớp catalog; với truy vấn mới không khớp, nó dùng vector trung bình làm phương án dự phòng. Khi đó, kết quả truy hồi chưa đo đầy đủ năng lực mã hóa query đa phương thức của SCALE. Tương tự, metadata reranking chỉ nên được xem là nguyên nhân của mức tăng khi nó được chạy end-to-end với tham số đã lưu và có log candidate trước/sau tái xếp hạng.

Vì vậy, metric thấp hơn không đồng nghĩa SCALE kém hơn kết quả công bố. Chúng phản ánh tổng hợp khác biệt về quy mô dữ liệu, protocol, positive definition, pipeline tiền xử

Table VI
KẾT QUẢ THAM CHIẾU SCALE KHI TĂNG SỐ MODALITY

Modality	Acc.	mAP@1	mAP@5	mAP@10	Prec@1	Prec@5	Prec@10
Text	77.42	47.70/65.10	53.63/68.39	51.59/66.99	47.70/65.10	30.96/44.89	24.15/33.44
+Image	79.58	51.47/67.02	56.16/69.85	54.41/68.43	51.47/67.02	33.41/46.29	25.55/34.29
+Table	82.83	57.14/67.97	61.71/70.34	59.64/69.38	57.14/67.97	38.02/46.85	28.99/34.36
+Video	84.31	58.57/69.79	63.15/72.30	61.02/70.67	58.57/69.79	39.26/47.44	29.56/34.78
+Audio	85.50	58.72/70.62	63.17/73.02	61.05/71.50	58.72/70.62	39.66/48.20	30.32/35.35

Table VII
KẾT QUẢ TÁI LẬP HIỆN CÓ: BASELINE VÀ CẤU HÌNH CẢI TIẾN

K	mAP (%)		Precision (%)		Δ mAP (điểm %)
	Baseline	Cải tiến	Baseline	Cải tiến	
1	5.17	14.94	5.17	14.94	+9.77
5	5.89	16.18	3.22	10.57	+10.29
10	6.32	16.75	3.56	8.68	+10.43

lý, checkpoint pretraining/fine-tuning và mức hoàn thiện hệ thống. Một manifest đầy đủ cho mỗi lần chạy, gồm split, seed, số query, checkpoint, tham số HNSW, trọng số reranking và latency, là điều kiện cần để xác định phần chênh lệch nào đến từ representation, phần nào đến từ serving.

XI. THẢO LUẬN

A. Tương tác giữa các Modality

Mỗi modality mô tả một phần khác nhau của sản phẩm. Image cung cấp appearance, text cung cấp semantic intent, table chứa thông tin fine-grained, video cung cấp use case và audio bổ sung lời giới thiệu. JCT cho phép các nguồn thông tin này tương tác, trong khi SIMCL tránh việc gán trọng số đồng đều cho mọi cặp modality.

B. Thiếu Modality

Zero imputation cho phép mẫu thiếu modality vẫn được giữ trong training và catalog. Đây là yếu tố quan trọng đối với e-commerce vì listing không phải lúc nào cũng có đủ ảnh, text, table, video và audio. Tuy nhiên, nếu một query hoặc một catalog item chỉ có rất ít tín hiệu, embedding có thể kém phân biệt.

C. Nhiễu thị giác (Visual Noise)

Ảnh listing thường có chữ quảng cáo, watermark, logo shop, người, vật tưng hoặc nhiều biến thể trong cùng frame. Region feature của Faster R-CNN giảm một phần vấn đề nhưng chưa đảm bảo loại bỏ hoàn toàn background và object phụ. Metadata reranking được thiết kế để xử lý một phần lỗi fine-grained sau bước retrieval.

D. Giới hạn hiện thực và khả năng suy diễn

Việc rà soát mã nguồn cho thấy phần đánh giá có thể tính metric trên positive set theo nhãn, nhưng kết quả đang lưu không kèm manifest thực nghiệm. Ngoài ra, lớp API hiện tham chiếu các thành phần tái xếp hạng chưa có trong cây mã nguồn; nhánh encoder theo SCALE chỉ trả embedding đã lưu khi title

khớp catalog và dùng vector trung bình làm phương án dự phòng. Vì vậy, báo cáo chỉ diễn giải reranking như *phương pháp đề xuất* cho tới khi các thành phần này được bổ sung và truy vấn ảnh/text mới được mã hóa thực sự bằng checkpoint SCALE. Đây là ranh giới cần nêu rõ để không diễn giải quá mức các metric trong Bảng ??.

XII. HƯỚNG PHÁT TRIỂN TƯƠNG LAI

Ba hướng ưu tiên để hoàn thiện hệ thống là:

- **Ablation và tái lập có kiểm soát:** đánh giá lần lượt SCALE exact retrieval, SCALE + HNSW, và SCALE + HNSW + metadata reranking trên cùng split; sau đó tách các nhóm query image-only, image+text và có table. Ablation theo số modality, nhiều seed, cùng manifest gồm checkpoint, split, positive definition, tham số index và trọng số reranking sẽ cho biết chính xác thành phần nào tạo ra mức tăng.
- **Tích hợp pipeline chuẩn SCALE:** thay các bước được đơn giản hóa do giới hạn phần cứng bằng cấu hình sát paper hơn: sampling video 1 frame/giây, audio MFCC, feature extractor và checkpoint pretraining/fine-tuning tương thích. Mục tiêu là để representation của query và catalog được tạo bởi cùng pipeline SCALE, từ đó so sánh công bằng hơn với kết quả công bố.
- **Frontend đánh giá trực quan:** xây dựng giao diện cho phép tải query image hoặc image+text, hiển thị Top-K, metadata, điểm embedding, điểm reranking và thời gian phản hồi. Việc quan sát trực tiếp các trường hợp đúng/sai và thu nhận phản hồi người dùng sẽ hỗ trợ hiệu chỉnh trọng số, xác nhận category suy luận và đánh giá trải nghiệm retrieval end-to-end.

XIII. KẾT LUẬN

Bài báo trình bày thiết kế visual product search mở rộng thành multimodal retrieval cho catalog thương mại điện tử. SCALE là backbone biểu diễn năm modality, còn Faiss HNSW và attribute-aware reranking là lớp serving được đề xuất để cân bằng tốc độ với tính đúng đắn theo thuộc tính. Trên các kết quả hiện có, cấu hình cải tiến đạt mAP@10 16.75% so với 6.32% của baseline và Precision@10 8.68% so với 3.56%.

Đóng góp chính của bản báo cáo là tách bạch ba mức bằng chứng: số liệu tham chiếu từ bài báo SCALE, kết quả tái lập nội bộ đã lưu, và hệ thống end-to-end cần hoàn thiện. Bước tiếp theo là lưu đầy đủ manifest, hoàn thiện mã reranking/encoder truy vấn mới, rồi đánh giá exact retrieval, HNSW và reranking trên cùng split. Cách báo cáo này tránh

nhằm lẫn giữa chất lượng representation, chất lượng ANN và hiệu năng hệ thống.

REFERENCES

- [1] N. Venkatesan, M. Suresh, V. R. Paul, D. K. Das, and P. Vijayakumar, "The Rise of Visual Search in E-Commerce: Leveraging AI to Redefine Product Discovery," *Journal of Marketing & Social Research*, 2025.
- [2] X. Dong, X. Zhan, Y. Wu, Y. Wei, M. C. Kampffmeyer, X.-Y. Wei, M. Lu, Y. Wang, and X. Liang, "M5Product: Self-harmonized Contrastive Learning for E-commercial Multi-modal Pretraining," 2022.
- [3] P. Nadkarni and N. V. Dasararaju, "Visually Similar Products Retrieval for Shopsy," *arXiv:2210.04560*, 2022.
- [4] C. Liu, P. Hou, A. Zeng, and H. Yu, "Transformer-Empowered Multi-Modal Item Embedding for Enhanced Image Search in E-commerce," in *Proc. AAAI*, 2024.
- [5] H. Jiang, H. Zhang, Q. Hou, C. Chen, W. Lin, J. Zhang, and A. Wang, "MRSE: An Efficient Multi-modality Retrieval System for Large Scale E-commerce," 2024.
- [6] P. Yuan, B. Mei, and H. Zhang, "FashionMV: Product-Level Composed Image Retrieval with Multi-View Fashion Data," *arXiv:2604.10297*, 2026.
- [7] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2017.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. CVPR*, 2016.
- [9] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in *Proc. NAACL-HLT*, 2019.
- [10] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," in *Proc. ICML*, 2021.
- [11] Y. A. Malkov and D. A. Yashunin, "Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2020.
- [12] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, 2019.
- [13] A. Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *Proc. ICLR*, 2021.
- [14] P. Anderson et al., "Bottom-Up and Top-Down Attention for Image Captioning and Visual Question Answering," in *Proc. CVPR*, 2018.
- [15] R. Krishna et al., "Visual Genome: Connecting Language and Vision Using Crowdsourced Dense Image Annotations," *Int. J. Comput. Vis.*, 2017.
- [16] A. Vaswani et al., "Attention Is All You Need," in *Advances in Neural Information Processing Systems*, 2017.
- [17] S. Davis and P. Mermelstein, "Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences," *IEEE Trans. Acoust., Speech, Signal Process.*, 1980.
- [18] Meta AI, "Faiss Documentation." [Online]. Available: <https://faiss.ai/>
- [19] PyTorch Contributors, "PyTorch." [Online]. Available: <https://pytorch.org/>
- [20] Hugging Face, "Transformers Documentation." [Online]. Available: <https://huggingface.co/docs/transformers>
- [21] Librosa Developers, "librosa Documentation." [Online]. Available: <https://librosa.org/doc/latest/>
- [22] FFmpeg Developers, "FFmpeg Documentation." [Online]. Available: <https://ffmpeg.org/documentation.html>

APPENDIX: KÝ HIỆU

Table VIII
DANH SÁCH KÝ HIỆU VÀ Ý NGHĨA

Ký hiệu	Ý nghĩa
$q = (I, T, Tab, V, A)$	Query đa phương thức (Image, Text, Table, Video, Audio); tối thiểu Image hoặc Video.
$G = \{p_1, \dots, p_N\}$	Kho sản phẩm.
p_i	Một listing, cùng bộ năm modality, có thể thiếu nhánh.
K	Số kết quả trả về.
N	Số ứng viên lọc thô HNSW, $N > K$.
$f(\cdot)$	SCALE encoder, unified embedding.
$\text{sim}(\cdot)/S_{\text{emb}}$	Độ tương đồng embedding (inner product sau L2-normalize).
S	Alignment score matrix trong SIMCL.
$S(u, v)$	Mức hỗ trợ semantic giữa hai modality.
$S_{\text{thuoc_tinh}}$	Điểm khớp siêu danh mục / danh mục / thông số.
S_{tong}	$\lambda S_{\text{emb}} + (1 - \lambda) S_{\text{thuoc_tinh}}$.
SD, D	Siêu danh mục, danh mục (D^* là thương hiệu đa số).
$I(\cdot)$	Hàm chỉ thị; 0 nếu thiếu thành phần query.
JCT	Joint Cross-modal Transformer.
SIMCL	Self-harmonized Inter-Modality Contrastive Learning.
HNSW	Hierarchical Navigable Small World (Faiss).